


Informe de limpieza y dashboard AMIE

Línea Temática 03: Datos
Reto 1: Del CSV al dashboard

Prácticum Interno · Semana 03

Estudiante	David Merino
Carrera / ciclo	4 ciclo
Tutor	Francisco Vargas
Fecha	20/05/2026
Herramientas	Python, pandas, SQLite, DB Browser y Power BI



1. Introducción

En este trabajo se desarrolló el Reto 1 de la Línea Temática 03: Datos. El objetivo fue trabajar con archivos CSV reales del dataset AMIE del Ministerio de Educación del Ecuador, limpiarlos con Python, cargarlos en una base de datos SQLite y construir un dashboard en Power BI.

El proceso no consistió solamente en cargar datos y generar gráficos. Primero fue necesario revisar la estructura de los archivos, corregir diferencias entre columnas, normalizar textos, tratar valores vacíos, convertir tipos de datos y comprobar que los resultados fueran correctos. Con esa base limpia se elaboraron tres visualizaciones alineadas con las preguntas del reto.

El resultado final fue un dashboard que permite observar la matrícula total por provincia en el año lectivo más reciente, comparar instituciones fiscales y particulares por área urbana o rural en Loja, y analizar la evolución de instituciones activas en Ecuador entre 2015 y 2024.

2. Descripción del dataset

El dataset utilizado corresponde al Archivo Maestro de Instituciones Educativas, conocido como AMIE. Este registro contiene información de instituciones educativas del Ecuador, como código AMIE, nombre de la institución, zona, provincia, cantón, parroquia, sostenimiento, área y matrícula total.

Para este reto se trabajó con archivos desde el año lectivo 2015-2016 hasta el año lectivo 2023-2024. Como cada archivo representaba un periodo distinto, fue necesario unificarlos en una sola estructura para analizarlos de manera conjunta.

Años lectivos trabajados	Fuente de datos	Uso en el reto
2015-2016 a 2023-2024	Archivos CSV del dataset AMIE	Limpieza, carga en SQLite, consultas SQL y dashboard

Al tratarse de datos reales, los archivos no estaban completamente listos para ser usados directamente. Se identificaron diferencias de estructura, problemas de codificación, espacios innecesarios y encabezados ubicados en distintas filas.

3. Herramientas utilizadas

Herramienta	Uso dentro del proyecto
Python	Ejecución del proceso de limpieza y transformación.
pandas	Lectura, normalización, limpieza y unión de los CSV.
SQLite	Almacenamiento local del dataset limpio.
DB Browser for SQLite	Validación de consultas SQL y resultados.
Power BI	Construcción del dashboard y visualizaciones.
Visual Studio Code	Edición y ejecución de scripts Python y SQL.

4. Proceso de limpieza con pandas

La limpieza se realizó en el archivo principal limpieza_amie.py. Este script lee todos los CSV ubicados en la carpeta data, detecta el encabezado real de cada archivo, estandariza las columnas, limpia los datos y genera una salida unificada.

Un punto importante fue que no todos los CSV tenían exactamente la misma estructura. Por eso, el código no asumió que el encabezado estaba siempre en la primera fila, sino que buscó la fila donde aparecían campos clave como AMIE, Provincia y Año lectivo.

Las columnas finales utilizadas para el dashboard fueron:

Columna	Descripción
Año lectivo	Periodo al que corresponde el registro.
AMIE	Código único de la institución educativa.
Nombre_Institución	Nombre del establecimiento educativo.
Zona	Zona administrativa.
Provincia	Provincia donde se ubica la institución.
Cantón	Cantón donde se ubica la institución.
Parroquia	Parroquia correspondiente.
Sostenimiento	Tipo de sostenimiento: fiscal, particular, fiscomisional o municipal.
Área	Área urbana o rural.
Matricula_Total	Total de estudiantes matriculados.

Además, se eliminaron filas sin información clave, se limpiaron espacios en blanco, se revisaron duplicados y se convirtió Matricula_Total a número entero. Este último ajuste fue necesario porque Power BI estaba interpretando mal valores con decimales, como 1054187.0.

También se utilizó un script auxiliar llamado `diagnostico_2023.py`. Este archivo quedó dentro de la carpeta pruebas, ya que sirvió para revisar el CSV 2023-2024, que presentaba diferencias frente a los demás archivos. El script definitivo del proceso es `limpieza_amie.py`.

PRÁCTICUM 1.2

db

Practicum 1.2

data

amie2015-2016.csv

amie2016-2017.csv

amie2017-2018.csv

amie2018-2019.csv

amie2019-2020.csv

amie2020-2021.csv

amie2021-2022.csv

amie2022-2023.csv

amie2023-2024.csv

db

amie.db

pruebas

diagnostico_2023.py

salida

amie_limpio.csv

columnas_amie.txt

consultas.sql

limpieza_amie.py

salida

PROBLEMS

OUTPUT

DEBUG CONSOLE

TERMINAL

PORTS

PS C:\Users\david\Downloads\Practicum 1.2\Practicum 1.2> py limpieza_amie.py

ARCHIVOS ENCONTRADOS:
data\amie2015-2016.csv
data\amie2016-2017.csv
data\amie2017-2018.csv
data\amie2018-2019.csv
data\amie2019-2020.csv
data\amie2020-2021.csv
data\amie2021-2022.csv
data\amie2022-2023.csv
data\amie2023-2024.csv

Leyendo archivo: data\amie2015-2016.csv
Matrícula tomada desde columna resumen: Total_Estudiantes
Filas leídas: 18582
Años encontrados: ['2015-2016 Fin']

Leyendo archivo: data\amie2016-2017.csv
Matrícula tomada desde columna resumen: Total_Estudiantes
Filas leídas: 17097
Años encontrados: ['2016-2017 Fin']

Leyendo archivo: data\amie2017-2018.csv
Matrícula tomada desde columna resumen: Total_Estudiantes
Filas leídas: 16714
Años encontrados: ['2017-2018 Fin']

Leyendo archivo: data\amie2018-2019.csv
Matrícula tomada desde columna resumen: Total_Estudiantes
Filas leídas: 16600
Años encontrados: ['2018-2019 Fin']

Leyendo archivo: data\amie2019-2020.csv
Matrícula tomada desde columna resumen: Total_Estudiantes
Filas leídas: 16455
Años encontrados: ['2019-2020 Fin']

Leyendo archivo: data\amie2020-2021.csv
Matrícula tomada desde columna resumen: Total_Estudiantes
Filas leídas: 16285

Build with Agent

AI responses may be inaccurate

Generate Agent Instructions to onboard onto your codebase.

Local

Default Approvals

Ln 84, Col 3 Spaces: 4 UTF-8 CRLF Python Python 3.13 (64-bit)

PRÁCTICUM 1.2

db

Practicum 1.2

data

amie2015-2016.csv

amie2016-2017.csv

amie2017-2018.csv

amie2018-2019.csv

amie2019-2020.csv

amie2020-2021.csv

amie2021-2022.csv

amie2022-2023.csv

amie2023-2024.csv

db

amie.db

pruebas

diagnostico_2023.py

salida

amie_limpio.csv

columnas_amie.txt

consultas.sql

limpieza_amie.py

salida

PROBLEMS

OUTPUT

DEBUG CONSOLE

TERMINAL

PORTS

Leyendo archivo: data\amie2021-2022.csv
Matrícula tomada desde columna resumen: Total_Estudiantes
Filas leídas: 16131
Años encontrados: ['2021-2022 Fin']

Leyendo archivo: data\amie2022-2023.csv
Matrícula tomada desde columna resumen: Total_Estudiantes
Filas leídas: 16088
Años encontrados: ['2022-2023 Fin']

Leyendo archivo: data\amie2023-2024.csv
Matrícula tomada desde columna resumen: Total_Estudiantes
Filas leídas: 16206
Años encontrados: ['2023-2024 Fin', '']

DATASET UNIFICADO CORRECTAMENTE
Filas y columnas originales: (150158, 10)
Filas duplicadas exactas encontradas: 0

Columnas con valores nulos:
Series([], dtype: int64)

LIMPIEZA FINALIZADA
Filas y columnas finales: (150155, 10)
Archivo limpio guardado en: salida/amie_limpio.csv
Listado de columnas guardado en: salida/columnas_amie.txt


BASE DE DATOS CREADA CORRECTAMENTE
total_registros
0 150155

INSTITUCIONES POR AÑO:
Año lectivo total_instituciones
0 2015-2016 Fin 18582
1 2016-2017 Fin 17097
2 2017-2018 Fin 16714
3 2018-2019 Fin 16600
4 2019-2020 Fin 16455
5 2020-2021 Fin 16285
6 2021-2022 Fin 16131
7 2022-2023 Fin 16088

Local

Default Approvals

Ln 84, Col 3 Spaces: 4 UTF-8 CRLF Python Python 3.13 (64-bit)



5. Resultados de la limpieza

Después de ejecutar el script, se generaron los archivos de salida necesarios para continuar el análisis:

Archivo generado	Función
salida/amie_limpio.csv	Archivo limpio para Power BI.
salida/columnas_amie.txt	Listado de columnas finales.
db/amie.db	Base de datos SQLite con la tabla amie.

El dataset final quedó con 150155 registros y 10 columnas. Para el año lectivo 2023-2024 se verificó un total nacional de 4214508 estudiantes.


Provincia	Matrícula total 2023-2024
GUAYAS	1,054,187
PICHINCHA	696,690
MANABÍ	400,376
LOS RÍOS	226,634
AZUAY	198,198

Estos resultados fueron validados desde Python y también mediante consultas SQL en DB Browser.

6. Carga en SQLite

Una vez limpio el dataset, los datos fueron cargados en una base SQLite llamada amie.db. Dentro de la base se creó una tabla principal llamada amie.

La carga en SQLite permitió comprobar los datos antes de visualizarlos en Power BI. De esta forma, si un gráfico mostraba un valor extraño, se podía contrastar con una consulta SQL y verificar si el problema estaba en los datos o en la configuración del gráfico.



DB Browser for SQLite - C:\Users\david\OneDrive\Desktop\Practicum 1.2 mala\db\amie.db

File Edit View Tools Help

New Database Open Database Write Changes Revert Changes Undo Open Project Save Project Attach Database Close Database

Database Structure Browse Data Edit Pragma Execute SQL

Create Table Create Index Modify Table Delete Table Print Refresh

Name Type Schema

Choose a database file

Desktop > Practicum 1.2 mala > db

Organizar Nueva carpeta

Documentos Imágenes Música Videos db salida dashboard_amie

Nombre de archivo: amie SQLite database files (*.db *.sql)

Abrir Cancelar

DB Browser for SQLite - C:\Users\david\OneDrive\Desktop\Practicum 1.2 mala\db\amie.db

File Edit View Tools Help

New Database Open Database Write Changes Revert Changes Undo Open Project Save Project Attach Database Close Database

Database Structure Browse Data Edit Pragma Execute SQL

Table: amie

	Año lectivo	AMIE	Nombre_Institución	Zona	Provincia	Cantón	Parroquia
1	2015-2016 Fin	01B00020	COLEGIO INTERCULTURAL BILINGUE DE ...	ZONA 6	AZUAY	CUENCA	BAÑOS
2	2015-2016 Fin	01B00021	ESCUELA DE EDUCACION BASICA SEIS DE ...	ZONA 6	AZUAY	CUENCA	CHACHA
3	2015-2016 Fin	01B00027	CECIB DE EDUCACION BASICA MONSEÑOR ...	ZONA 6	AZUAY	CUENCA	QUINGEO
4	2015-2016 Fin	01B00028	CECIB DE EDUCACION BASICA ESTRELLA D...	ZONA 6	AZUAY	CUENCA	QUINGEO
5	2015-2016 Fin	01B00029	CECIB DE EDUCACIÓN BÁSICA EL TEJAR	ZONA 6	AZUAY	CUENCA	QUINGEO
6	2015-2016 Fin	01B00030	ESCUELA DE EDUCACIÓN BÁSICA ...	ZONA 6	AZUAY	CUENCA	RICAUITE
7	2015-2016 Fin	01B00031	CECIB DE EDUCACION BASICA MONTE SINAI	ZONA 6	AZUAY	CUENCA	SANTA ANA
8	2015-2016 Fin	01B00032	ESCUELA DE EDUCACIÓN BÁSICA XAVIER ...	ZONA 6	AZUAY	CUENCA	TURI
9	2015-2016 Fin	01B00034	CECIB DE EDUCACIÓN BÁSICA CESAR ...	ZONA 6	AZUAY	CUENCA	TURI
10	2015-2016 Fin	01B00035	ESCUELA DE EDUCACIÓN BÁSICA MARCO ...	ZONA 6	AZUAY	CUENCA	TURI
11	2015-2016 Fin	01B00036	CECIB DE EDUCACIÓN BÁSICA JUAN ...	ZONA 6	AZUAY	CUENCA	SANTA ANA
12	2015-2016 Fin	01B00037	CECIB DE EDUCACIÓN BÁSICA MIGUEL ...	ZONA 6	AZUAY	GUALACEO	GUALACEO
13	2015-2016 Fin	01B00041	ESCUELA DE EDUCACIÓN BÁSICA LA ...	ZONA 6	AZUAY	GUALACEO	SAN JUAN
14	2015-2016 Fin	01B00043	ESCUELA DE EDUCACIÓN BÁSICA RUMINAHUI	ZONA 6	AZUAY	GUALACEO	ZHIMAD
15	2015-2016 Fin	01B00045	CECIB DE EDUCACIÓN BÁSICA EFRAIN ...	ZONA 6	AZUAY	NABON	NABON
16	2015-2016 Fin	01B00046	CECIB DE EDUCACIÓN BÁSICA ARTURO ...	ZONA 6	AZUAY	NABON	NABON
17	2015-2016 Fin	01B00047	CECIB DE EDUCACION BÁSICA MONSEÑOR ...	ZONA 6	AZUAY	NABON	NABON
18	2015-2016 Fin	01B00048	CECIB DE EDUCACIÓN BÁSICA SAN JOSÉ	ZONA 6	AZUAY	NABON	NABON
19	2015-2016 Fin	01B00049	CECIB DE EDUCACIÓN BÁSICA CESAR ...	ZONA 6	AZUAY	NABON	NABON
20	2015-2016 Fin	01B00050	CECIB DE EDUCACIÓN BÁSICA JOSÉ ...	ZONA 6	AZUAY	NABON	NABON
21	2015-2016 Fin	01B00051	UNIDAD EDUCATIVA COMUNITARIA ...	ZONA 6	AZUAY	NABON	NABON
22	2015-2016 Fin	01B00052	ESCUELA DE EDUCACIÓN BÁSICA BALTAZAR...	ZONA 6	AZUAY	NABON	NABON
23	2015-2016 Fin	01B00053	CECIB DE EDUCACIÓN BÁSICA FERNANDO ...	ZONA 6	AZUAY	NABON	NABON

Edit Database Cell

Mode: Text

1

Identification of the cell currently in the editor
Type and size of data currently in table

Remote

Identity Select an identity to connect

DBHub.io Local Current Database

Name Last modified Size

The screenshot shows the DB Browser for SQLite interface. The SQL editor contains the following query:

```

1 SELECT
2   "Provincia",
3   SUM("Matricula_Total") AS matricula_total
4 FROM amie
5 WHERE "Año lectivo" = '2023-2024 Fin'
6 GROUP BY "Provincia"
7 ORDER BY matricula_total DESC;

```

The results pane displays a table with two columns: Provincia and matricula_total. The data is sorted in descending order of matricula_total.

Provincia	matricula_total
1 GUAYAS	1054187
2 PICHINCHA	696690
3 MANABI	400376
4 LOS RIOS	226634
5 AZUAY	198198
6 EL ORO	172523
7 ESMERALDAS	163604
8 SANTO DOMINGO DE LOS TSACHILAS	134910
9 TUNGURAHUA	132124
10 COTOPAXI	119586
11 IMBABURA	119501
12 LOJA	117054
13 CHIMBORAZO	113097
14 SANTA ELENA	107530
15 MORONA SANTIAGO	66530
16 SUCUMBIDOS	65547
17 CAÑAR	61937
18 ORELLANA	59331
19 BOLIVAR	48302

7. Consultas SQL realizadas

Se creó el archivo consultas.sql con las consultas usadas para validar los resultados del dashboard. Las tres consultas principales fueron las siguientes:

Consulta 1: matrícula total por provincia en el año lectivo más reciente

```

SELECT
  "Provincia",
  SUM("Matricula_Total") AS matricula_total
FROM amie
WHERE "Año lectivo" = '2023-2024 Fin'
GROUP BY "Provincia"
ORDER BY matricula_total DESC;

```

D8 Browser for SQLite - C:\Users\david\OneDrive\Desktop\Practicum 1.2 mala\db\amie.db

FileEditViewToolsHelp

New DatabaseOpen DatabaseWrite ChangesRevert ChangesUndoOpen ProjectSave ProjectAttach DatabaseClose Database

Database StructureBrowse DataEdit PragmaExecute SQL

SQL 1*

```
1 SELECT
2     "Provincia",
3     SUM("Matricula_Total") AS matricula_total
4 FROM amie
5 WHERE "Año lectivo" = '2023-2024 Fin'
6 GROUP BY "Provincia"
7 ORDER BY matricula_total DESC;
```

	Provincia	matricula_total
1	GUAYAS	1054187
2	PICHINCHA	696690
3	MANABI	400376
4	LOS RIOS	226634
5	AZUAY	198198
6	EL ORO	172523
7	ESMERALDAS	163604
8	SANTO DOMINGO DE LOS TSACHILAS	134910
9	TUNGURAHUA	132124
10	COTOPAXI	119586
11	IMBABURA	119501
12	LOJA	117054
13	CHIMBORAZO	113097
14	SANTA ELENA	107530
15	MORONA SANTIAGO	66530
16	SUCUMBIOS	65547
17	CAÑAR	61937
18	ORELLANA	59331
19	BOLIVAR	48302

Edit Database Cell

Mode: Text

NULL

No cell active.
Type: NULL; Size: 0 bytes

Remote

Identity Select an identity to connect

DBHub.ioLocalCurrent Database

NameLa

Consulta 2: instituciones fiscales vs. particulares por área en Loja

```
SELECT
    "Área",
    "Sostenimiento",
    COUNT(DISTINCT "AMIE") AS total_instituciones
FROM amie
WHERE "Año lectivo" = '2023-2024 Fin'
    AND "Provincia" = 'LOJA'
    AND "Sostenimiento" IN ('FISCAL', 'PARTICULAR')
GROUP BY "Área", "Sostenimiento"
ORDER BY "Área", "Sostenimiento";
```


DB Browser for SQLite - C:\Users\david\OneDrive\Desktop\Practicum 1.2 mala\db\amie.db

File Edit View Tools Help

New Database Open Database Write Changes Revert Changes Undo Open Project Save Project Attach Database Close Database

Database Structure Browse Data Edit Pragma Execute SQL

SQL 1*

```

1 SELECT
2     "Área",
3     "Sostenimiento",
4     COUNT(DISTINCT "AMIE") AS total_instituciones
5 FROM amie
6 WHERE "Año lectivo" = '2023-2024 Fin'
7     AND "Provincia" = 'LOJA'
8     AND "Sostenimiento" IN ('FISCAL', 'PARTICULAR')
9 GROUP BY "Área", "Sostenimiento"
10 ORDER BY "Área", "Sostenimiento";

```

	Área	Sostenimiento	total_instituciones
1	RURAL	FISCAL	646
2	RURAL	PARTICULAR	1
3	URBANA	FISCAL	318
4	URBANA	PARTICULAR	60

Consulta 3: evolución de instituciones activas

```

SELECT
    "Año lectivo",
    COUNT(DISTINCT "AMIE") AS instituciones_activas
FROM amie
GROUP BY "Año lectivo"
ORDER BY "Año lectivo";

```

DB Browser for SQLite - C:\Users\david\OneDrive\Desktop\Practicum 1.2 mala\db\amie.db

File Edit View Tools Help

New Database Open Database Write Changes Revert Changes Undo Open Project Save Project Attach Database Close Database

Database Structure Browse Data Edit Pragmas Execute SQL

SQL 1*

```
1 SELECT
2     "Año lectivo",
3     COUNT(DISTINCT "AMIE") AS instituciones_activas
4 FROM amie
5 GROUP BY "Año lectivo"
6 ORDER BY "Año lectivo";
```

	Año lectivo		instituciones_activas
1	2015-2016 Fin		18582
2	2016-2017 Fin		17097
3	2017-2018 Fin		16714
4	2018-2019 Fin		16600
5	2019-2020 Fin		16455
6	2020-2021 Fin		16285
7	2021-2022 Fin		16131
8	2022-2023 Fin		16088
9	2023-2024 Fin		16203


8. Dashboard en Power BI

El dashboard fue construido en Power BI usando el archivo limpio salida/amie_limpio.csv. Se elaboraron tres visualizaciones, cada una vinculada con una pregunta del reto.

Visualización 1: Matrícula total por provincia

La primera visualización muestra la matrícula total por provincia en el año lectivo 2023-2024. Para esto se utilizó Provincia en el eje X y la suma de Matricula_Total en el eje Y. Se aplicó el filtro Año lectivo = 2023-2024 Fin.

El resultado muestra que Guayas es la provincia con mayor matrícula, seguida por Pichincha y Manabí. Este resultado coincidió con la consulta SQL realizada en DB Browser.




Visualización 2: Instituciones fiscales vs. particulares por área en Loja

La segunda visualización compara instituciones fiscales y particulares en la provincia de Loja, separadas por área urbana y rural. En este caso no se usó matrícula, sino el recuento distinto de AMIE, porque cada código AMIE representa una institución educativa.

Los filtros aplicados fueron: Provincia = LOJA, Año lectivo = 2023-2024 Fin y Sostenimiento = FISCAL y PARTICULAR.


CAPTURA 8: Power BI - instituciones fiscales vs. particulares en Loja




Visualización 3: Evolución de instituciones activas

La tercera visualización muestra cómo ha cambiado la cantidad de instituciones activas en Ecuador entre 2015 y 2024. Se utilizó Año lectivo en el eje X y el recuento distinto de AMIE en el eje Y.

El gráfico permitió observar la variación del número de instituciones activas a lo largo del periodo analizado.





9. Limitaciones encontradas

- Los archivos CSV no tenían una estructura completamente uniforme, por lo que fue necesario detectar encabezados y estandarizar columnas.
- El archivo 2023-2024 requirió una revisión adicional mediante `diagnostico_2023.py` antes de integrarse correctamente con los demás años.
- Algunos valores de matrícula fueron leídos inicialmente con decimales, lo cual causó problemas de interpretación en Power BI. Esto se corrigió convirtiendo `Matricula_Total` a número entero.
- Fue necesario validar los resultados con SQL para asegurar que los gráficos no mostraran valores inflados o mal interpretados.

10. Conclusiones

El reto permitió construir un proceso completo de trabajo con datos, desde archivos CSV originales hasta un dashboard funcional en Power BI. La limpieza con pandas fue una parte fundamental, ya que permitió unificar archivos de distintos años y dejarlos en una estructura común.

La carga en SQLite ayudó a validar los resultados antes de presentarlos visualmente. Gracias a las consultas SQL se pudo comprobar que las cifras mostradas en Power BI coincidían con los datos almacenados en la base.

Finalmente, el dashboard respondió las tres preguntas planteadas: matrícula total por provincia, comparación de instituciones fiscales y particulares por área en Loja, y evolución de instituciones activas en Ecuador entre 2015 y 2024. El proceso demostró la importancia de limpiar y verificar los datos antes de analizarlos, ya que un pequeño error de formato puede afectar directamente los resultados visuales.

