

Estado del arte en ingeniería de datos: métodos, herramientas, aplicaciones y tendencias para el futuro

Universidad Técnica Particular de Loja (UTPL)

Dirección General de Tecnologías de la Información y Transformación Digital (DGTITD)

David Alejandro Merino Espinosa

Resumen—El análisis de datos se ha convertido en una capacidad fundamental para las organizaciones que buscan tomar decisiones basadas en evidencia y no únicamente en intuiciones. En el contexto institucional, su importancia radica en la posibilidad de transformar datos dispersos en indicadores, reportes y visualizaciones que permitan comprender mejor los procesos internos. Este documento presenta un estado del arte sobre ingeniería de datos, análisis de datos y visualización de información, considerando su aplicación en el reto del Prácticum Interno desarrollado en la Dirección General de Tecnologías de la Información y Transformación Digital de la UTPL. Se revisan conceptos clave como ETL/ELT, APIs, modelado de datos, calidad de datos, arquitectura medallón, dashboards y metodologías como CRISP-DM. Además, se analizan trabajos relacionados en la industria y en la educación superior, donde la analítica ha permitido mejorar procesos de seguimiento, planificación y toma de decisiones. También se describen herramientas actuales como SQL, Python, Pandas, NumPy, Jupyter, Apache Spark, dbt, Power BI, Tableau, Looker Studio, RPA y Prefect. Finalmente, se identifican tendencias futuras como la analítica aumentada, el análisis en tiempo real, la analítica de autoservicio, la analítica predictiva en educación superior y la visualización inteligente. Se concluye que la ingeniería de datos representa una oportunidad para que la DGTITD y la UTPL fortalezcan una cultura institucional basada en evidencia, siempre que se trabaje con datos confiables, bien gobernados, correctamente interpretados y presentados de manera clara.

Palabras clave—análisis de datos, ingeniería de datos, ETL, arquitectura medallón, visualización de datos, dashboards, analítica educativa, Power BI, Python, SQL, SQLite, RPA, Prefect, toma de decisiones.

I. INTRODUCCIÓN

Actualmente, los datos ya no son simples registros almacenados en sistemas informáticos; se han convertido en una fuente clave de conocimiento para las organizaciones. Cuando la información se analiza y organiza de manera adecuada, cada interacción digital, procedimiento administrativo, proceso académico o servicio institucional puede generar datos útiles para comprender una situación y actuar sobre ella. Por esta razón, el análisis de datos cumple un papel central: transforma registros dispersos en indicadores, patrones y evidencias que apoyan la toma de decisiones.

El análisis de datos permite examinar información con el fin de identificar comportamientos, explicar situaciones y evaluar resultados. Su importancia no se limita al ámbito empresarial; también influye en la academia, en los organismos públicos y en instituciones que necesitan comprender y mejorar sus procesos internos. En una universidad, por ejemplo, la analítica puede contribuir al seguimiento académico de los estudiantes, la evaluación de servicios, el reconocimiento de necesidades estudiantiles, el monitoreo de plataformas digitales y la mejora de la gestión institucional.

Este trabajo se desarrolla dentro del Prácticum Interno de la Dirección General de Tecnologías de la Información y Transformación Digital de la UTPL. De acuerdo con la metodología planteada para esta fase, el estado del arte debe permitir conocer qué se está realizando actualmente en el campo escogido, qué actores lo están aplicando, qué herramientas se emplean y cuáles son las tendencias que podrían orientar su evolución durante los próximos años. Por ello, el documento no se limita a presentar definiciones, sino que relaciona los conceptos con el reto práctico

desarrollado: la construcción de un pipeline de datos del macroentorno ecuatoriano.

Bajo esta orientación, el documento analiza el estado actual de la ingeniería y el análisis de datos, sus aplicaciones más comunes, las tecnologías que se utilizan en esta área y las líneas de evolución que podrían marcar su desarrollo entre 2025 y 2028. La intención es comprender cómo estas prácticas pueden aportar valor en escenarios institucionales donde se requiere tomar decisiones con información confiable, trazable y comunicada de manera clara.

El trabajo se organiza en varias etapas. Primero, se presenta el contexto del reto y su relación con la ingeniería de datos. Luego, se desarrolla un marco conceptual con los términos necesarios para comprender el tema. Posteriormente, se revisan trabajos y experiencias relacionadas en la industria y en la educación superior. Después se describen herramientas y tecnologías empleadas en el área, con énfasis en aquellas aplicadas al reto. Finalmente, se analizan tendencias futuras y se plantean conclusiones orientadas al contexto de la UTPL y la DGTITD.

II. CONTEXTO DEL RETO DEL PRÁCTICUM

A. *Propósito del reto*

El reto del Prácticum se enfoca en construir un flujo de datos reproducible que permita pasar desde archivos fuente hasta indicadores preparados para análisis. En lugar de trabajar con datos aislados, el proyecto integra información económica, educativa y empresarial. Para ello se consideraron datos del Banco Central del Ecuador, del Ministerio de Educación y de Supercias, incluyendo archivos generados o entregados mediante procesos de automatización tipo RPA.

La finalidad de esta integración fue construir una visión del macroentorno ecuatoriano a partir de distintas dimensiones. La información económica permitió revisar indicadores nacionales y provinciales; los datos educativos aportaron registros relacionados con bachillerato; y la información empresarial permitió analizar compañías activas por provincia y sector. De esta manera, el reto no se limitó a limpiar archivos, sino que buscó conectar fuentes diferentes para generar información útil en un dashboard analítico.

B. Arquitectura de trabajo

Para ordenar el proceso se utilizó una arquitectura por capas. En la capa Bronze se conservaron los archivos originales sin modificaciones; en la capa Silver se almacenaron los datos limpios y normalizados; y en la capa Gold se generaron vistas e indicadores listos para el consumo en Power BI. Esta separación permitió mantener trazabilidad, evitar mezclar archivos crudos con resultados finales y explicar de forma sencilla el recorrido de los datos desde su origen hasta la visualización.

La arquitectura elegida también permitió relacionar el reto con una práctica habitual en ingeniería de datos. En proyectos reales, la información suele llegar desde varias fuentes, con formatos, nombres de columnas y estructuras diferentes. Por ello, resulta necesario diseñar un flujo que no dependa de una limpieza manual ocasional, sino de scripts organizados, reglas de transformación y salidas verificables.

C. Alcance tecnológico

El alcance del reto no requería una infraestructura empresarial compleja ni procesamiento distribuido. Por esta razón se seleccionaron herramientas ligeras, revisables y adecuadas para el nivel académico del proyecto. Python y Pandas se utilizaron para la limpieza y transformación; SQLite funcionó como base relacional portable; DB Browser permitió inspeccionar tablas y vistas; Power BI se empleó para la visualización; y Prefect se incorporó como herramienta de orquestación para evidenciar la ejecución programada del flujo.

III. MARCO CONCEPTUAL

A. Ingeniería de datos

La ingeniería de datos se encarga de preparar el camino para que los datos puedan ser utilizados correctamente. Esto implica construir y mantener sistemas que permiten recolectar, almacenar, transformar y entregar información confiable a otras áreas como analítica, ciencia de datos o visualización. Sin este trabajo previo, sería difícil generar reportes, dashboards o modelos, porque la información podría estar incompleta, desordenada o dispersa en varios sistemas [1].

El ciclo de vida de la ingeniería de datos permite comprender cómo se mueve la información dentro de una organización. Reis y Housley explican que este ciclo incluye etapas como generación, ingesta, almacenamiento, transformación y entrega de datos [1]. Los datos se generan en sistemas, plataformas o aplicaciones; luego se extraen o reciben desde distintas fuentes; después se almacenan en repositorios; posteriormente se transforman para mejorar su

calidad; y finalmente se entregan a usuarios, aplicaciones o tableros.

Aunque la ingeniería de datos, la ciencia de datos y la analítica de datos trabajan con el mismo recurso, no cumplen exactamente la misma función. La ingeniería de datos se enfoca en la infraestructura y en los flujos que permiten mover y preparar la información. La ciencia de datos utiliza métodos estadísticos, algoritmos y aprendizaje automático para construir modelos. La analítica de datos, en cambio, se orienta a interpretar la información y apoyar la toma de decisiones. Nazabal et al. señalan que una parte importante del trabajo analítico depende de tareas previas como adquirir, limpiar y preparar los datos [2].

B. ETL y ELT

En los proyectos de datos, la información casi nunca llega lista para ser analizada. Por ello se utilizan procesos como ETL y ELT. ETL significa extraer, transformar y cargar datos; es decir, primero se obtiene la información desde sus fuentes, luego se limpia o modifica, y finalmente se guarda en un repositorio de destino. ELT lo hace de manera diferente: primero carga los datos y después realiza las transformaciones dentro de una plataforma de almacenamiento [3].

Esta diferencia es importante porque influye en la forma en que se preparan los datos antes de crear reportes, indicadores o tableros. En un entorno académico o institucional, un enfoque ETL resulta útil cuando se desea validar los datos antes de cargarlos en una base. En otros escenarios, especialmente cuando se trabaja con plataformas modernas de datos, el enfoque ELT permite aprovechar la capacidad de procesamiento del destino.

C. APIs como fuente de datos

Las APIs permiten que distintos sistemas intercambien información de manera estructurada. En análisis de datos son importantes porque muchas veces la información no se obtiene manualmente, sino desde plataformas académicas, sistemas institucionales, aplicaciones internas o servicios externos. Por ejemplo, una universidad podría usar APIs para consultar datos de matrícula, asistencia, solicitudes, plataformas virtuales o servicios digitales.

Para trabajar con APIs también se deben considerar aspectos técnicos como autenticación, límites de consulta, formatos de respuesta, paginación, control de errores y seguridad. Aunque el reto desarrollado se apoyó principalmente en archivos descargados o generados por otros procesos, comprender el papel de las APIs es relevante porque muchas soluciones futuras podrían obtener datos de servicios conectados y no solo de archivos locales.

D. Modelado de datos

El modelado de datos permite organizar la información para que pueda ser consultada y analizada con mayor facilidad. No se trata únicamente de guardar datos, sino de estructurarlos de acuerdo con las preguntas que se quieren responder. En inteligencia de negocios, Inmon propone una visión integrada del data warehouse, mientras que Kimball plantea el modelado dimensional mediante tablas de hechos y dimensiones [4], [5].

En una universidad, este modelado podría aplicarse a estudiantes, asignaturas, matrículas, calificaciones, docentes, solicitudes o servicios digitales. En el reto del macroentorno ecuatoriano, el modelado permitió separar dimensiones como geografía y tiempo, y relacionarlas con hechos económicos, educativos y empresariales. Esta organización facilita la construcción de consultas y evita trabajar con archivos separados que no comparten una estructura común.

E. Calidad de datos

La calidad de datos influye directamente en la confiabilidad del análisis. Si la información utilizada contiene errores, registros duplicados, campos vacíos o inconsistencias, los resultados pueden llevar a conclusiones equivocadas. Wand y Wang explican que la calidad de datos se relaciona con dimensiones como exactitud, completitud, consistencia y oportunidad [6].

Por esta razón, antes de analizar normalmente se revisan los datos, se limpian errores, se corrigen formatos y se eliminan duplicados. En un pipeline, la calidad no debe considerarse una tarea secundaria, sino una condición para que las visualizaciones y decisiones posteriores sean confiables. Un dashboard puede ser visualmente atractivo, pero si los datos no fueron preparados correctamente, el resultado pierde valor.

F. Visualización de datos

La visualización de datos permite comunicar los resultados del análisis de forma clara. Un análisis puede estar técnicamente bien elaborado, pero si no se entiende, pierde gran parte de su utilidad. Herramientas como Power BI, Tableau y Looker Studio permiten construir dashboards con gráficos, filtros e indicadores que ayudan a interpretar datos sin tener que revisar directamente las tablas [7], [8].

En el contexto universitario, estos tableros podrían utilizarse para revisar matrícula, rendimiento académico, uso de plataformas, atención de solicitudes o indicadores administrativos. Un buen dashboard no debe estar lleno de gráficos sin orden, sino mostrar la información necesaria para responder una pregunta concreta. Few señala que un tablero debe comunicar la información más importante de forma clara, rápida y efectiva [16].

G. Metodologías para proyectos de datos

Los proyectos de análisis de datos requieren una metodología para evitar el trabajo improvisado. Una de las más conocidas es CRISP-DM, que organiza el proceso en seis etapas: comprensión del negocio, comprensión de los datos, preparación de datos, modelado, evaluación y despliegue [9]. Esta metodología ayuda a empezar por el problema y no directamente por la herramienta.

En otras palabras, antes de programar o crear gráficos se debe entender qué se quiere resolver, qué datos existen, qué calidad tienen, cómo serán procesados y cómo se evaluará si el resultado realmente sirve. Esta lógica se relaciona con el reto del Prácticum, porque el proyecto exigió comprender las fuentes, organizarlas, transformarlas y presentarlas en un dashboard útil para usuarios no necesariamente técnicos.

IV. TRABAJOS RELACIONADOS

A. Casos de industria

Uno de los casos más conocidos de uso de análisis de datos en la industria es Netflix. Su sistema de recomendación utiliza datos de interacción de los usuarios para personalizar contenidos y mejorar la experiencia dentro de la plataforma. Amatriain y Basilico explican que Netflix ha usado técnicas de recomendación, personalización y minería de datos para analizar distintos tipos de información generada por sus usuarios [10]. Este caso muestra que el análisis de datos puede convertirse en una parte central del funcionamiento de un servicio digital.

Otro ejemplo importante se encuentra en el uso de inteligencia de negocios y analítica en organizaciones que necesitan tomar decisiones con grandes volúmenes de información. Chen, Chiang y Storey señalan que el crecimiento del Big Data impulsó el desarrollo de la inteligencia de negocios y la analítica como áreas clave para transformar datos en conocimiento útil [11]. Esta idea es relevante porque conecta directamente el análisis de datos con la toma de decisiones basada en evidencia.

B. Casos en educación superior

En las universidades, el análisis de datos se ha utilizado para mejorar la gestión académica, el seguimiento estudiantil y la planificación institucional. Ong revisa once casos de instituciones de educación superior del Reino Unido que aplicaron proyectos de Business Intelligence y Big Data Analytics. Estos proyectos abordaron temas como rendimiento estudiantil, retención, progresión académica, carga de trabajo, admisiones y planificación estratégica [12].

Un caso relacionado es el de iniciativas de analítica académica orientadas al éxito estudiantil. Campbell, DeBlois y Oblinger plantean que la analítica académica permite transformar registros universitarios en información útil para orientar decisiones institucionales [13]. Estos enfoques muestran que las universidades no solo usan datos para reportes, sino también para comprender mejor sus procesos internos, anticipar problemas y apoyar estrategias de mejora.

C. Analítica de aprendizaje

La analítica del aprendizaje es un campo cercano al análisis de datos en universidades. Se enfoca en recopilar y analizar datos generados por estudiantes en plataformas, cursos y entornos digitales para comprender y mejorar los procesos educativos. Siemens define la analítica del aprendizaje como una disciplina emergente orientada a interpretar datos educativos con fines de mejora académica [14].

Más recientemente, Molla-Esparza et al. señalan que la analítica del aprendizaje en educación superior se ha aplicado al estudio del rendimiento académico, aunque los resultados y enfoques todavía son diversos [15]. Esto significa que el análisis de datos en educación no es solo una tendencia tecnológica, sino un campo de investigación activo que ayuda a tomar decisiones sobre desempeño, permanencia, acompañamiento y mejora institucional.

D. Relación con la UTPL y la DGTID

Los trabajos revisados permiten observar que el análisis de datos puede aplicarse tanto en empresas digitales como en instituciones educativas. En la UTPL, estas experiencias pueden servir como referencia para construir indicadores académicos, tableros de seguimiento, análisis de uso de plataformas, estudios de rendimiento estudiantil o reportes para la toma de decisiones. Además, los casos de educación superior muestran que el valor del análisis no está únicamente en tener datos, sino en organizarlos, garantizar su consistencia, interpretarlos y convertirlos en acciones útiles para la institución.

V. HERRAMIENTAS Y TECNOLOGÍAS

A. SQL y bases de datos

SQL sigue siendo una herramienta clave en el análisis de datos porque permite consultar bases relacionales, filtrar registros, combinar tablas, agrupar información y crear indicadores. En entornos académicos o administrativos, SQL ayuda a extraer datos de distintos sistemas antes de analizarlos o visualizarlos. En el reto del Prácticum, el uso de SQL se relacionó con la creación de consultas y vistas sobre una base SQLite.

SQLite fue adecuado para el alcance del proyecto porque permite trabajar con una base de datos liviana y portable. A diferencia de motores empresariales más complejos, no requiere levantar un servidor, lo que facilita su revisión por parte de docentes o evaluadores. DB Browser complementó este trabajo al permitir inspeccionar tablas, vistas y consultas de manera visual.

B. Python, Pandas, NumPy y Jupyter

Python es uno de los lenguajes más utilizados para análisis de datos por su flexibilidad y por el ecosistema de librerías disponibles. McKinney destaca el uso de Python junto con Pandas, NumPy y Jupyter para manipular, limpiar, procesar y analizar datos tabulares [7]. Pandas facilita el trabajo con estructuras tipo tabla, NumPy permite operaciones numéricas y Jupyter ayuda a documentar el proceso usando código, resultados y explicación.

En el reto desarrollado, Python y Pandas fueron centrales para leer archivos, normalizar columnas, transformar tipos de datos, limpiar texto y generar salidas procesadas. Estas tareas muestran que el valor de Python no está solo en ejecutar código, sino en automatizar pasos repetitivos para que el proceso pueda repetirse de forma ordenada.

C. Apache Spark y PySpark

Apache Spark es una tecnología utilizada en el procesamiento de grandes volúmenes de datos. Zaharia et al. señalan que Spark permite unir varias cargas de trabajo, como procesamiento por lotes, consultas interactivas y aprendizaje automático dentro de un mismo entorno [8]. PySpark permite utilizar Spark desde Python, lo cual facilita su integración con proyectos donde ya se emplea este lenguaje.

Aunque Spark forma parte del estado del arte de la ingeniería de datos, no todos los proyectos requieren esta escala. En el reto del Prácticum, el volumen y el alcance fueron atendidos de manera suficiente con Python, Pandas y SQLite. Sin embargo, conocer Spark es importante porque representa una opción para escenarios futuros donde

el volumen de información crezca o se requiera procesamiento distribuido.

D. dbt y transformación analítica

dbt, o Data Build Tool, se utiliza para transformar datos dentro de flujos ELT mediante SQL. Su valor se encuentra en aplicar prácticas de ingeniería de software al trabajo analítico, como modularidad, pruebas, documentación y control de versiones. En este sentido, dbt ayuda a que los datos cargados en un almacén puedan convertirse en modelos más limpios y útiles para reportes, análisis o dashboards [17].

Aunque dbt no fue una herramienta central en la solución implementada, su revisión resulta pertinente dentro del estado del arte porque muestra cómo los proyectos modernos buscan transformar datos de manera ordenada y reproducible. Este principio sí se aplicó en el reto mediante scripts organizados, vistas Gold y una estructura clara del repositorio.

E. Power BI, Tableau y Looker Studio

Power BI, Tableau y Looker Studio son herramientas de visualización e inteligencia de negocios. Se utilizan para construir dashboards e informes interactivos que permitan interpretar indicadores sin revisar directamente las bases de datos. Chen, Chiang y Storey explican que la inteligencia de negocios y la analítica permiten convertir grandes volúmenes de datos en información útil para la toma de decisiones [11].

En el proyecto del macroentorno ecuatoriano se utilizó Power BI porque permite conectar datos procesados, crear visualizaciones, incorporar filtros y comunicar resultados de forma accesible. La visualización fue la última etapa del flujo, después de la limpieza, el modelado y la generación de vistas Gold.

F. RPA y automatización de entrada de datos

La automatización robótica de procesos, conocida como RPA, permite ejecutar tareas repetitivas mediante reglas o flujos automáticos. En proyectos de datos, el RPA puede utilizarse para descargar archivos, consolidar reportes, extraer información de sistemas o dejar archivos en una carpeta de entrada para su procesamiento posterior. Esta lógica se relaciona con el reto, donde los archivos de Supercias se recibieron en una carpeta de entrada y fueron procesados por el pipeline.

El valor del RPA dentro del flujo no está en reemplazar el análisis, sino en reducir tareas manuales de obtención o entrega de archivos. Una vez que los datos llegan a la carpeta de entrada, la ingeniería de datos se encarga de validarlos, transformarlos y cargarlos en la base correspondiente.

G. Prefect y orquestación de flujos

Prefect es una herramienta de orquestación que permite definir, ejecutar, programar y monitorear flujos de trabajo. En un pipeline de datos, la orquestación ayuda a controlar el orden de las tareas, registrar ejecuciones, revisar estados y detectar fallos. En el reto, Prefect permitió registrar el flujo del pipeline, desplegarlo como una automatización y programarlo cada seis horas.

Esta incorporación fue relevante porque permitió evidenciar que el proceso no depende únicamente de ejecutar comandos manuales. A través del dashboard de Prefect se puede observar el deployment, el horario programado, las ejecuciones, los logs y el estado de cada corrida. Esto fortalece la reproducibilidad del proyecto.

TABLA I
SÍNTESIS DE HERRAMIENTAS

Capa	Herramientas	Uso principal
Consulta	SQL	Extraer y agrupar datos
Análisis	Python, Pandas	Limpiar y transformar
Documentación	Jupyter/Colab	Mostrar código y resultados
Gran escala	Spark/PySpark	Procesar alto volumen
Modelado	dbt	Transformar con SQL
Visualización	Power BI/Tableau	Crear dashboards
Orquestación	Prefect	Programar flujos

VI. APLICACIÓN AL RETO DEL MACROENTORNO ECUATORIANO

A. Fuentes integradas

La aplicación práctica del estado del arte se materializó en el pipeline del macroentorno ecuatoriano. El proyecto integró fuentes económicas, educativas y empresariales. Desde el Banco Central del Ecuador se consideraron indicadores como PIB, petróleo, riesgo país, VAB e IEE. Desde el Ministerio de Educación se utilizó información relacionada con registros administrativos de educación. Desde Supercias se procesó información empresarial proveniente de archivos entregados mediante RPA.

La integración de estas fuentes permitió construir una visión más amplia del contexto. En lugar de presentar datos aislados, el pipeline organizó la información para responder preguntas vinculadas con la economía nacional, la producción provincial y la relación entre educación y actividad empresarial.

B. Capas Bronze, Silver y Gold

La capa Bronze conservó los archivos originales para mantener trazabilidad. La capa Silver almacenó datos limpios y normalizados, como archivos de bachillerato, PIB, indicadores diarios, VAB, IEE y directorio de empresas. La capa Gold organizó la información en vistas y archivos listos para Power BI. Esta estructura permitió separar claramente los insumos originales de los resultados analíticos.

La organización por capas también facilitó la explicación del proyecto a personas no técnicas. Bronze representa el punto de partida; Silver representa la preparación de datos; y Gold representa la información ya lista para responder preguntas de análisis. Esta forma de presentar el proceso evita que el proyecto parezca una colección de archivos sueltos.

C. Base relacional y vistas analíticas

La base SQLite funcionó como repositorio central. En ella se cargaron dimensiones y tablas de hechos relacionadas con geografía, tiempo, indicadores económicos, educación y empresas. Sobre estas tablas se construyeron vistas Gold, entre ellas las orientadas a PIB, petróleo, VAB por provincia, bachilleres por provincia, empresas por provincia y relación entre bachilleres y empresas.

El uso de vistas permitió entregar a Power BI información ya preparada. Esto es importante porque el dashboard no debe asumir toda la lógica de transformación. En una solución ordenada, la visualización consume indicadores previamente validados y no archivos sin depurar.

D. Dashboard en Power BI

El dashboard final se organizó en tres páginas. La primera presentó indicadores de economía nacional, como PIB real, variación del PIB y precio del petróleo WTI. La segunda se enfocó en producción provincial, principalmente a través del VAB por provincia y por sector económico. La tercera vinculó educación y actividad empresarial mediante bachilleres por provincia y empresas activas por provincia.

Esta estructura buscó que usuarios no técnicos pudieran comprender los resultados sin revisar scripts ni bases de datos. Las visualizaciones fueron diseñadas para mostrar tendencias, comparaciones y relaciones principales. Por ello, Power BI cumplió una función de comunicación, no de limpieza de datos.

E. Automatización con Prefect

En la etapa final se incorporó Prefect para evidenciar la automatización del pipeline. El flujo quedó desplegado como un deployment llamado automatizacion-rpa y programado para ejecutarse cada seis horas. Esta frecuencia fue seleccionada porque los archivos de Supercias pueden ser pesados y no requieren reprocesamiento constante cada pocos minutos.

El uso de Prefect permitió mostrar una interfaz web con el flujo, el schedule, el estado y las ejecuciones. Esto aporta valor académico porque demuestra que el pipeline puede ser observado y programado, acercándose a la manera en que se gestionan procesos de datos en entornos profesionales.

TABLA II
RELACIÓN ENTRE RETO Y PIPELINE

Etapa	Resultado	Valor
Bronze	Fuentes BCE, MINEDUC y RPA	Trazabilidad
Silver	Limpieza con Python	Datos consistentes
SQLite	Tablas y vistas	Validación SQL
Gold	Excel para Power BI	Indicadores listos
Power BI	Dashboard final	Comunicación visual
Prefect	Ejecución cada 6 h	Automatización

Esta decisión muestra que automatizar no significa ejecutar un proceso constantemente sin criterio. Una buena automatización debe responder al comportamiento de las fuentes, al volumen de datos y a la necesidad real de actualización. En el reto, la programación periódica cumple con el requisito de ejecución sin intervención manual y mantiene un equilibrio razonable entre oportunidad y eficiencia.

La frecuencia de seis horas se definió considerando el tipo de datos y el peso de los archivos procesados. En este caso, las fuentes no requieren actualización minuto a minuto, y algunos archivos de entrada pueden ser pesados. Ejecutar el pipeline con demasiada frecuencia generaría procesamiento innecesario. En cambio, una programación cada seis horas mantiene la automatización y al mismo tiempo respeta el costo de procesamiento.

G. Pertinencia de la frecuencia de actualización

El uso de Prefect aporta evidencia visual del proceso: muestra el nombre del flujo, el deployment, el horario de ejecución, el estado y las corridas programadas. Para un entorno académico, esta característica permite explicar de manera clara cómo se controla el pipeline. Para un entorno profesional, representa una práctica cercana a la orquestación real de procesos de datos.

La automatización se incorporó como una extensión natural del pipeline. Primero se creó una lógica capaz de revisar la carpeta de entrada RPA y procesar los archivos disponibles. Después, el flujo se registró en Prefect para que pudiera observarse desde una interfaz web y programarse periódicamente. Esto permite demostrar que el proceso no termina en un script manual, sino que puede ser supervisado como un flujo de datos.

F. Automatización y supervisión

La comunicación visual exige seleccionar pocos indicadores, pero relevantes. Un tablero con demasiados elementos puede confundir más de lo que ayuda. Por esa razón, el diseño final priorizó gráficos de tendencia, barras comparativas y filtros sencillos. Esta decisión se relaciona con el principio de que un dashboard debe apoyar una decisión o una lectura concreta, no mostrar datos por mostrar.

Uno de los objetivos de la visualización fue comunicar información a personas que no necesariamente conocen Python, SQL o ingeniería de datos. Por ello, el dashboard se organizó en páginas temáticas y no únicamente en tablas. La primera página presenta el comportamiento económico general; la segunda permite revisar diferencias provinciales; y la tercera relaciona educación con actividad empresarial. Esta estructura ayuda a que el usuario comprenda el propósito de cada vista.

E. Comunicación para usuarios no técnicos

Los indicadores Gold fueron pensados de acuerdo con las preguntas principales del reto. Para economía nacional se prepararon datos de PIB, variación anual y petróleo; para producción provincial se prepararon agregaciones de VAB; y para la relación entre educación y empresas se generaron indicadores de bachilleres y compañías activas por provincia. Esta selección permitió que el dashboard tenga una narrativa clara y no se convierta en una acumulación de gráficos desconectados.

La capa Gold se diseñó para evitar que Power BI recibiera datos sin preparación. En lugar de cargar todos los archivos procesados y construir la lógica directamente en el dashboard, se generaron vistas y salidas específicas para análisis. Esta decisión permite que el tablero se enfoque en comunicar resultados y no en resolver problemas de limpieza o modelado.

D. Diseño de indicadores Gold

Esta validación es necesaria porque la visualización puede ocultar problemas si no se revisa la base de origen. Un gráfico puede parecer correcto a simple vista, pero si la tabla tiene duplicados, campos mal tipados o relaciones inconsistentes, la interpretación será débil. Por ello, el trabajo en SQLite sirvió como punto intermedio entre los archivos limpios y Power BI, asegurando que el dashboard se construyera sobre una fuente organizada.

La base SQLite cumplió una función de validación, no solo de almacenamiento. Una vez cargadas las tablas, fue posible revisar cantidades de registros, consultar campos principales, verificar vistas y comprobar si los indicadores respondían a las preguntas del reto. DB Browser permitió observar la estructura de la base y ejecutar consultas SQL de control sin necesidad de usar un servidor de base de datos empresarial.

C. Validación mediante base de datos

Este enfoque reduce la dependencia de operaciones manuales y facilita la revisión del trabajo. Si se actualiza una fuente o se agrega un nuevo archivo proveniente de RPA, el proceso puede volver a ejecutarse manteniendo la misma lógica de transformación. En términos académicos, la reproducibilidad fortalece la confiabilidad del proyecto, porque muestra que los resultados no dependen de una intervención aislada, sino de un procedimiento documentado.

La reproducibilidad consiste en que el proceso pueda ejecutarse nuevamente y obtener resultados coherentes sin rehacer manualmente cada paso. Para cumplir con este criterio, el pipeline se estructuró en scripts que procesan cada fuente y luego ejecutan una secuencia general desde el archivo principal. De esta manera, la limpieza, la carga a SQLite, la creación de vistas y la exportación para Power BI forman parte de un flujo ordenado.

B. Reproducibilidad del proceso

La trazabilidad también se refleja en la separación entre scripts, archivos procesados, base de datos y dashboard. Una persona externa al proyecto puede identificar qué archivos fueron fuente, qué scripts realizaron las transformaciones, qué tablas quedaron cargadas en SQLite y qué vistas fueron exportadas hacia Power BI. Esta organización es importante porque un proyecto académico de datos no debe evaluarse únicamente por el gráfico final, sino por la claridad del proceso completo.

Un criterio central del reto fue conservar la trazabilidad de la información. En proyectos de ingeniería de datos, la trazabilidad permite conocer de dónde proviene cada archivo, qué transformación recibió y en qué resultado final se utilizó. Por esta razón, la capa Bronze no se trató como una carpeta secundaria, sino como el punto de partida del proceso. Mantener los archivos originales permite revisar el origen de los datos si en el futuro aparece una diferencia en un indicador o si se requiere repetir el procesamiento con nuevas reglas.

A. Trazabilidad de la información

VII. CRITERIOS DE DISEÑO Y VALIDACIÓN DEL PIPELINE

De esta manera, el documento cumple una doble función: por un lado, presenta una revisión académica sobre ingeniería de datos; por otro, justifica las decisiones aplicadas en el reto del macroentorno ecuatoriano. Esta relación entre teoría y práctica es importante porque demuestra que las herramientas no fueron usadas de manera aislada, sino dentro de una metodología coherente con el objetivo del Prácticum.

El estado del arte revisado no queda separado del trabajo práctico. Los conceptos de ETL, calidad de datos, modelado, dashboards y orquestación se reflejan directamente en la solución construida. La revisión teórica permitió comprender por qué era necesario conservar datos originales, limpiar y normalizar archivos, cargar la información en una base relacional, crear vistas Gold y automatizar el flujo con una herramienta de monitoreo.

J. Relación entre estado del arte y práctica desarrollada

La solución también evita depender de infraestructura que no era necesaria para cumplir el objetivo. Motores empresariales o procesamiento distribuido pueden ser adecuados para otros escenarios, pero en este caso era más importante presentar un pipeline funcional, claro y reproducible. Esta decisión demuestra criterio técnico, porque una buena solución no siempre es la más compleja, sino la que responde mejor al problema, al volumen de datos y a los recursos disponibles.

El reto fue desarrollado en un contexto académico, por lo que la selección de herramientas debía ser proporcional al alcance del trabajo. Utilizar una base SQLite no disminuye el valor del proyecto; al contrario, permite construir una solución portable, verificable y suficiente para el volumen de datos trabajado. En este tipo de práctica, el objetivo principal es demostrar comprensión del flujo de ingeniería de datos: obtención, limpieza, modelado, almacenamiento, validación, visualización y automatización.

I. Criterio académico de la solución

Además, la documentación permite que el proyecto sea comprensible para personas que no participaron en su desarrollo. Esto es especialmente importante en el contexto del Prácticum, donde el trabajo debe ser evaluado no solo por quien lo construyó, sino también por docentes, tutores o revisores externos. Una estructura ordenada y documentada facilita comprobar que las decisiones técnicas responden a un propósito y no a una acumulación de archivos.

La documentación es una parte esencial de la sostenibilidad del proyecto. Un pipeline puede funcionar correctamente, pero si no se documenta su estructura, sus dependencias, sus fuentes y sus salidas, será difícil mantenerlo o revisarlo en el futuro. Por esta razón, el README del proyecto cumple la función de explicar la arquitectura, las herramientas utilizadas, las carpetas principales, el comando de ejecución, la automatización con Prefect y el archivo utilizado por Power BI.

H. Documentación y sostenibilidad del proyecto

VIII. TENDENCIAS Y FUTURO

A. Analítica aumentada

El análisis de datos está entrando en una etapa donde ya no basta con tener reportes o dashboards estáticos. La tendencia apunta a que los datos sean más fáciles de consultar, más rápidos de actualizar y más útiles para quienes toman decisiones. La analítica aumentada consiste en usar inteligencia artificial y aprendizaje automático para apoyar tareas que antes dependían mucho del trabajo manual del analista. Esto incluye detectar patrones, sugerir gráficos, explicar resultados o ayudar en la preparación de datos [18].

En un contexto institucional, la analítica aumentada podría ayudar a generar reportes más ágiles o detectar cambios importantes en indicadores sin revisar todo manualmente. Sin embargo, su aplicación debe estar acompañada por criterios de calidad y revisión humana, porque las sugerencias automáticas no reemplazan el conocimiento del contexto.

B. Análisis en tiempo real

Otra tendencia fuerte es trabajar con datos que se actualizan casi al momento en que ocurren. Antes era común esperar reportes semanales o mensuales; ahora muchas organizaciones necesitan reaccionar más rápido. Las arquitecturas de streaming, como las basadas en Apache Kafka, permiten procesar datos continuos y usarlos para monitoreo, alertas o análisis operativo [19].

En una universidad, esto podría aplicarse al seguimiento de plataformas digitales, incidencias tecnológicas o servicios que requieren respuesta rápida. Para el reto del Prácticum, la actualización programada con Prefect representa una aproximación académica a esta idea: no es streaming en tiempo real, pero sí reduce la dependencia de ejecuciones manuales.

C. Analítica de autoservicio

La analítica de autoservicio busca que más personas dentro de una organización puedan consultar datos y crear reportes sin depender siempre de un equipo técnico. Esto puede mejorar la velocidad de las decisiones, pero también trae riesgos si cada área interpreta los datos de forma distinta. Por ello, los estudios sobre democratización de datos señalan que el autoservicio debe acompañarse de gobierno, seguridad, alfabetización de datos y reglas claras de uso [20].

En el contexto de la UTPL, la analítica de autoservicio puede ser útil si se apoya en datos confiables y tableros bien diseñados. No se trata de que cada usuario construya indicadores sin control, sino de ofrecer información validada para que las áreas puedan tomar decisiones con mayor rapidez.

D. Analítica predictiva en educación superior

En educación superior, el análisis de datos se utiliza cada vez más para anticipar problemas académicos. La analítica del aprendizaje permite estudiar información generada en cursos, plataformas virtuales y procesos académicos para comprender mejor el rendimiento estudiantil [14], [15]. Esta tendencia puede servir para detectar estudiantes en riesgo, planificar tutorías, mejorar el acompañamiento y tomar decisiones antes de que el problema sea más difícil de corregir.

E. Visualización más inteligente

Los dashboards también están cambiando. Ya no se espera que solo muestren gráficos, sino que ayuden a interpretar qué está pasando. Cada vez será más común que las herramientas de visualización incluyan explicaciones automáticas, consultas en lenguaje natural y recomendaciones sobre los datos. Esto se relaciona con el storytelling con datos: no mostrar información por mostrar, sino ordenar los indicadores para que el usuario entienda el problema y pueda actuar.

F. Privacidad y uso responsable de datos

Mientras más datos se analizan, mayor es la responsabilidad sobre su uso. En instituciones educativas se trabaja con información sensible de estudiantes, docentes y procesos internos. Por eso, el futuro del análisis de datos no puede separarse de temas como privacidad, seguridad, control de accesos, sesgos y transparencia. Un análisis puede ser técnicamente correcto, pero si usa mal la información o expone datos personales, deja de ser una solución responsable.

G. Relevancia para la DGTITD

Para la DGTITD, estas tendencias pueden aterrizar en proyectos concretos: dashboards institucionales más claros, alertas tempranas, monitoreo de servicios digitales, reportes automáticos y análisis predictivo para apoyar procesos académicos o administrativos. El punto central es que el análisis de datos no debería quedarse en mostrar cifras, sino ayudar a comprender mejor lo que ocurre dentro de la Universidad y facilitar decisiones con evidencia.

IX. DISCUSIÓN

La revisión permite observar que el valor de un proyecto de datos no está únicamente en producir un dashboard final. Un tablero solo es confiable si existe una preparación previa adecuada. Por tanto, el reto del macroentorno ecuatoriano debe entenderse como una solución integral: organiza fuentes, transforma datos, los almacena, crea vistas analíticas, comunica resultados y automatiza el proceso.

También se evidencia que la elección tecnológica debe responder al alcance del proyecto. Herramientas como Spark o arquitecturas distribuidas son importantes en el estado del arte para escenarios de gran escala, pero no eran necesarias para este reto. En cambio, Python, Pandas, SQLite, Power BI y Prefect ofrecieron una combinación suficiente para desarrollar una solución clara, reproducible y revisable.

La estructura medallón permitió mostrar el proceso de forma comprensible. Para personas no relacionadas con el área técnica, Bronze, Silver y Gold funcionan como una explicación sencilla del recorrido de los datos: primero se conservan, luego se limpian y finalmente se preparan para análisis. Esta explicación evita que el proyecto se perciba como una serie de scripts aislados.

Finalmente, el contexto institucional de la UTPL y la DGTITD refuerza la importancia de trabajar con datos confiables. La toma de decisiones basada en evidencia requiere procesos ordenados, documentación, validación y herramientas que permitan comunicar resultados de manera entendible para usuarios técnicos y no técnicos.

X. CONCLUSIONES

El estado del arte confirma que la ingeniería de datos es la base sobre la cual se construyen análisis y visualizaciones confiables. Antes de generar gráficos, es necesario recolectar, limpiar, estructurar y validar datos. Por ello, conceptos como ETL, arquitectura medallón, calidad de datos, modelado relacional y automatización son elementos centrales para el reto desarrollado.

En el contexto del Prácticum, la solución propuesta responde a una necesidad concreta: integrar datos del macroentorno ecuatoriano en un flujo reproducible. La combinación de fuentes económicas, educativas y empresariales permite construir una visión más amplia que la que se obtendría al analizar cada fuente por separado.

La selección de Python, Pandas, SQLite, Power BI y Prefect resulta adecuada para el alcance académico del proyecto. Estas herramientas permiten implementar el flujo completo, desde la limpieza hasta la visualización y automatización, sin requerir infraestructura compleja. Además, facilitan la revisión del trabajo por parte de usuarios externos.

Finalmente, el análisis de datos representa una oportunidad para fortalecer una cultura institucional basada en evidencia. Su valor no está en acumular herramientas, sino en construir procesos claros que permitan transformar datos dispersos en información útil, comprensible y orientada a la toma de decisiones.

REFERENCIAS

- [1] J. Reis and M. Housley, *Fundamentals of Data Engineering: Plan and Build Robust Data Systems*. Sebastopol, CA, USA: O'Reilly Media, 2022.
- [2] A. Nazabal, C. K. I. Williams, G. Colavizza, C. R. Smith, and A. Williams, "Data engineering for data analytics: A classification of the issues, and case studies," *arXiv preprint arXiv:2004.12929*, 2020.
- [3] P. Vassiliadis, "A survey of extract-transform-load technology," *International Journal of Data Warehousing and Mining*, vol. 5, no. 3, pp. 1-27, 2009.
- [4] W. H. Inmon, *Building the Data Warehouse*, 4th ed. Indianapolis, IN, USA: Wiley, 2005.
- [5] R. Kimball and M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd ed. Indianapolis, IN, USA: Wiley, 2013.
- [6] Y. Wand and R. Y. Wang, "Anchoring data quality dimensions in ontological foundations," *Communications of the ACM*, vol. 39, no. 11, pp. 86-95, 1996.
- [7] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter*, 3rd ed. Sebastopol, CA, USA: O'Reilly Media, 2022.
- [8] M. Zaharia et al., "Apache Spark: A unified engine for Big Data processing," *Communications of the ACM*, vol. 59, no. 11, pp. 56-65, 2016.
- [9] P. Chapman et al., *CRISP-DM 1.0: Step-by-Step Data Mining Guide*. SPSS Inc., 2000.
- [10] X. Amatriain and J. Basilico, "Recommender systems in industry: A Netflix case study," in *Recommender Systems Handbook*, 2nd ed. Boston, MA, USA: Springer, 2015, pp. 385-419.
- [11] H. Chen, R. H. L. Chiang, and V. C. Storey, "Business intelligence and analytics: From Big Data to Big Impact," *MIS Quarterly*, vol. 36, no. 4, pp. 1165-1188, 2012.
- [12] V. K. Ong, "Business intelligence and Big Data analytics for higher education: Cases from UK higher education institutions," *Information Engineering Express*, vol. 2, no. 1, pp. 65-75, 2016.
- [13] J. P. Campbell, P. B. DeBlois, and D. G. Oblinger, "Academic analytics: A new tool for a new era," *EDUCAUSE Review*, vol. 42, no. 4, pp. 40-57, 2007.
- [14] G. Siemens, "Learning analytics: The emergence of a discipline," *American Behavioral Scientist*, vol. 57, no. 10, pp. 1380-1400, 2013.
- [15] C. Molla-Esparza, M. I. Gómez-Núñez, and F. J. García-García, "Applications of learning analytics in the study of academic performance in higher education: A pilot-tested meta-review protocol," *International Journal of Educational Research Open*, vol. 8, Art. no. 100433, 2025.

- [16] S. Few, Information Dashboard Design: The Effective Visual Communication of Data. Sebastopol, CA, USA: O'Reilly Media, 2006.
- [17] R. P. Machado and H. Russa, Analytics Engineering with SQL and dbt: Building Meaningful Data Models at Scale. Sebastopol, CA, USA: O'Reilly Media, 2023.
- [18] N. A. Alghamdi and H. H. Al-Baity, "Augmented analytics driven by AI: A digital transformation beyond business intelligence," Sensors, vol. 22, no. 20, Art. no. 8071, 2022.
- [19] T. P. Raptis, A. Passarella, and M. Conti, "A survey on networked data streaming with Apache Kafka," IEEE Access, vol. 11, pp. 85333-85350, 2023.
- [20] R. Murugan and S. Sekhar, "A literature review on data democratization, self-service business intelligence, and data literacy," International Journal of Business Analytics, vol. 12, no. 1, pp. 1-12, 2025.